PYTHON for 데이터 분석

2019. 03

Index

주요 패키지

- 데이터 처리
  - NumPy
  - Pandas
- 시각화
  - Matplotlib
  - Seaborn
- 머신 러닝
  - Scikit-learn

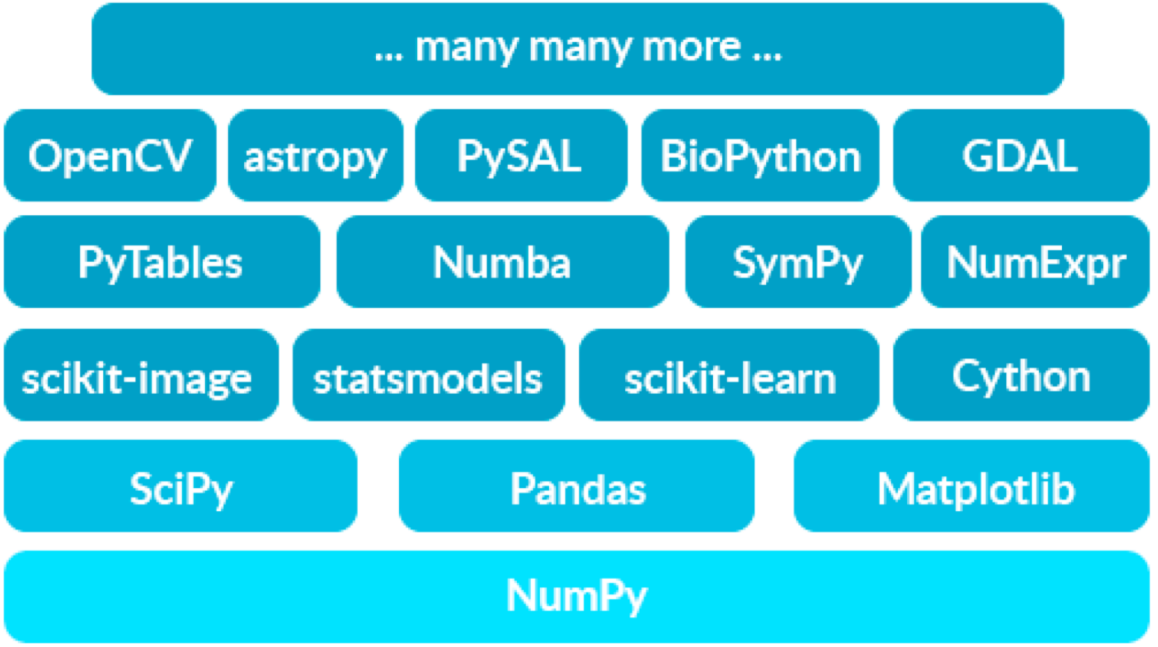

❑ numpy 개요

- **numpy는 과학 계산을 위한 라이브러리로서 다차원 배열을 처리하는데 필요한 여러 유용한 기능을 제공**
- **numpy 기본 데이타 타입은 ndarray**
- **array() 함수**
  - 리스트와 같은 다양한 인자를 입력받아서 ndarray로 변환하는 기능
- **한 개의 ndarray 내의 데이터 타입은 그 연산의 특성상 같은 데이터 타입만 가능**

❑ Indexing and slicing

- **indexing**
- **slicing**
  - 각 차원별로 슬라이스 범위를 지정
- **fancy indexing**
  - 정수 배열을 indexer로 사용해서 다차원 배열로 부터 Indexing하는 방법
- **boolean indexing**
  - 배열 각 요소의 선택여부를 True, False로 표현하는 방식

```
import numpy as np

# 1차원 배열 생성
a = np.array([1, 2, 3, 4, 5, 6])
# 2차원 배열 생성
b=  np.array([[1, 2, 3][4,5,6]])

# 1차원 indexing & slicing
a[0], a[0:3], a[1:], a[:-2]

# 2차원 indexing & slicing
b[1,1], b[0:2,0:2]

# fancy indexing
b[0,1]
b[[0,1], 1]

# boolean indexing
c = a[a >3]
```

❑ Indexing & slicing 참고(https://rfriend.tistory.com/290)

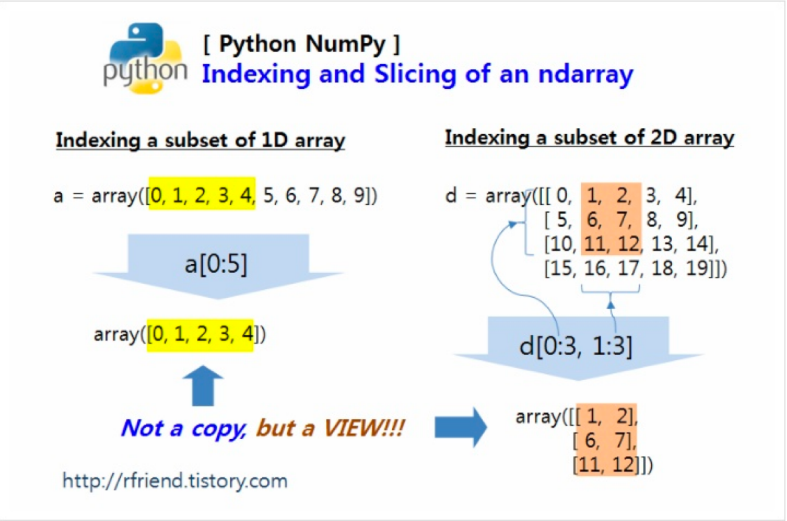

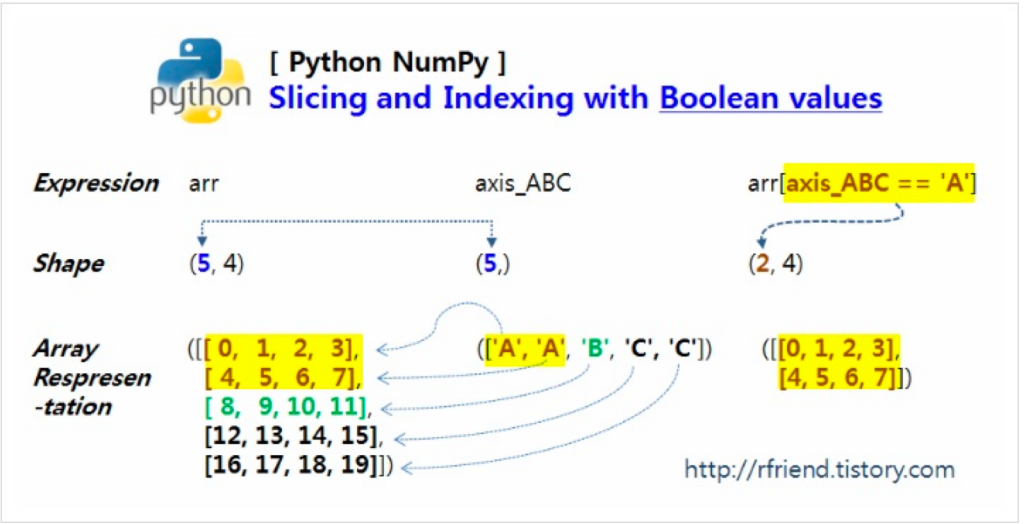

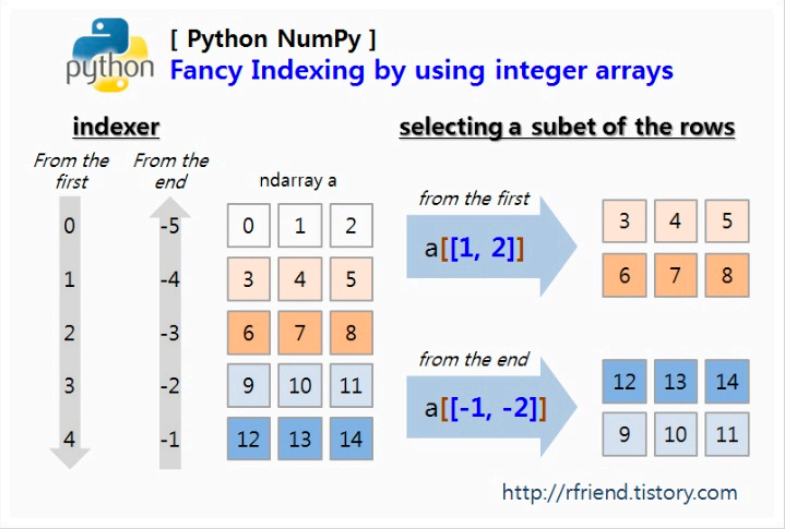

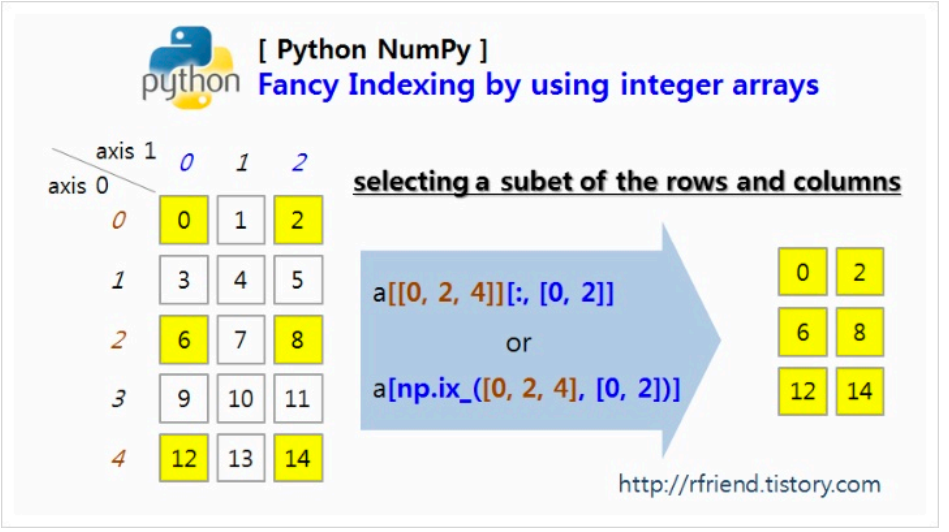

❑ array

- **주요 변수**
  - ndim, shape, dtype
- **주요 함수**
  - 생성
    - ✓ array()
    - ✓ arange(), zeros(), ones(), linespace()
  - 차원과 크기 변경
    - ✓ reshape(),
    - ✓ ravel(),
    - ✓ flatten()
    - ✓ astype()
  - 정렬
    - ✓ sort()
    - ✓ argsort()

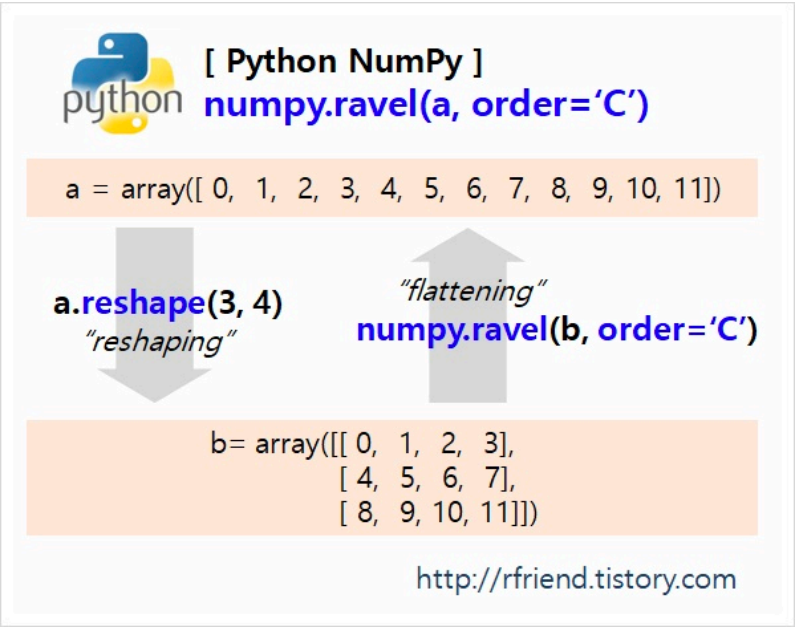

- **array 사용 시 주의할 점**
  - 길이가 5인 1차원 배열과 행(5,), 열의 갯수가 (5,1)인 2차원 배열 또는 행, 열의 갯수가 (1, 5)인 2차원 배열은 데이터가 같아도 엄연히 다른 객체라는 점이다.

NumPy

- **numpy array 장점**
  - **Size** - Numpy data structures take up less space
  - **Performance** - they have a need for speed and are faster than lists
  - **Functionality** - SciPy and NumPy have optimized functions such as linear algebra operations built in.
- **numpy array vs. list**
  - **하나의 array는 동일한 데이터 타입만 지원**
    - ✓ [1, 2, 3]
    - ✓ [[1, 2, 3]
      [4, 5, 6]]
  - **하나의 list는 여러가지 데이터 타입으로 가능**
    - ✓ [1, 2, 3, 'a', 'b', 'c']
- **numpy array vs. matrix**
  - **matrix는 배열 중 2차원과 동일**
- **Numpy array의 indexing and slicing의 결과는 original array에 대한 view를 제공**
  - **즉, slicing 결과에 대한 변경이 original array에 영향을 미침**
  - **Indexing한 배열을 copy(복사)하려면 copy() 사용**
  - **단 fancy indexing은 copy를 제공하므로 영향이 없음**

❑ pandas 개요

- pandas는 데이타 분석(Data Analysis)을 위해 널리 사용되는 파이썬 라이브러리 패키지이다
- **Series**
  - 1차원 자료구조
  - 배열/리스트 같은 일련의 시퀀스 데이터를 받아들인다
  - 별도의 인덱스 레이블을 지정하지 않으면 자동적으로 0부터 시작되는 정수 인덱스 사용
- **DataFrame**
  - 2차원 자료구조
  - 행과 열이 있는 테이블 데이터(Tabular Data)를 받아들인다.
- **Panel**
  - 3차원 자료구조
  - Axis0(items), Axis1(major_axis), Axis2(minor_axis)등 3개 축을 가지고 있다.
  - Axis 0은 하나의 요소가 2차원의 DataFrame에 해당하며
  - Axis 1은 DataFrame의 행(row)에 해당하고,
  - Axis 2는 DataFrame의 열(column)에 해당된다

❑ Data selecting and filtering

- **'[]' operator**
  - **column name**
    - ✓ df['col1']
  - **column name list**
    - ✓ df[['col1', 'col2']]
  - **인덱스로 변환 가능한 표현식**
    - ✓ 슬라이싱
      - df[0:2], df[0:], df[:-1]
    - ✓ 불린 인덱싱
      - df[df['col1'] ==0]

- ~~**ix(deprecated 예정)**~~
- **iloc**
  - **위치(position) 기반**
- **loc**
  - **명칭(label) 기반**

❑ 주요 함수

- Aggregation
- groupby
- sort_values
- isnull
- fillna
- apply
  - 행이나 열 단위로 더 복잡한 처리를 하고 싶을 때 사용
  - 인수로 행 또는 열을 받는 함수를 appy 메서드의 인수로 넣으면 각 열(또는 행)을 반복하여 그 함수에 적용시킨다